

Projet Machine Learning

Magomed Tsitsiev, Nouannapha Phichith

Mars 2026

1 Introduction

La pandémie de COVID-19 a provoqué une détérioration sans précédent de la santé mentale aux États-Unis. Pour mesurer cet impact en temps réel, le *U.S. Census Bureau* et le *CDC* ont lancé le *Household Pulse Survey* en avril 2020, collectant des données sur les symptômes d'anxiété et de dépression auprès de la population adulte américaine.

Dans ce projet, nous exploitons le jeu de données **Indicators of Anxiety or Depression** (OpenML ID 46760), couvrant la période **2020–2024**. Contrairement à une approche statique, nous avons enrichi ce dataset avec des variables socio-économiques (revenu médian, taux de pauvreté, éducation, assurance santé) issues de l'*American Community Survey*, tout en intégrant des **données de chômage dynamiques** synchronisées mensuellement pour capturer l'évolution réelle du contexte économique au fil des mois.

Notre travail s'articule autour de trois tâches de machine learning :

1. **Régression supervisée** : Prédire le taux de symptômes de dépression à partir des indicateurs économiques et sociaux de chaque État.
2. **Classification supervisée** : Prédire si un État présente un taux de dépression élevé ou modéré (en utilisant un seuil de prévalence de 22 %), afin d'identifier les zones géographiques prioritaires.
3. **Analyse non supervisée** : Segmenter les États américains en groupes homogènes (clusters) pour identifier des profils de vulnérabilité socio-économique similaires.

Le rapport est organisé comme suit : nous présentons d'abord le dataset et son exploration (section 1 et 2), la méthodologie d'enrichissement et de traitement des données (section 3), l'analyse critique des biais et de l'importance des variables (section 4), et enfin le développement ainsi que l'évaluation des trois tâches de machine learning (sections 4, 5 et 6). Le rapport se conclut par une synthèse des résultats obtenus, suivie de perspectives d'amélioration et de prolongement du travail (section 7).

1.1 Description du jeu de données : Source et contexte

Le jeu de données *Indicators of Anxiety or Depression* provient du Household Pulse Survey, une initiative conjointe du U.S. Census Bureau et des Centers for Disease Control and Prevention (CDC). Lancée en avril 2020, cette enquête expérimentale a été conçue pour mesurer rapidement l'impact social et économique de la pandémie de COVID-19 sur les ménages américains. Elle intègre notamment des questions issues du Patient Health Questionnaire à deux items (PHQ-2) et du Generalized Anxiety Disorder scale à deux items (GAD-2), qui permettent de dépister les symptômes de trouble dépressif majeur et de trouble anxieux généralisé. Le jeu de données est disponible publiquement sur Kaggle¹ ainsi que sur OpenML (ID 46760). Chaque ligne représente une **statistique agrégée** : le pourcentage estimé d'adultes déclarant des symptômes d'anxiété, de dépression ou des deux, au sein d'un sous-groupe démographique donné et pour une période temporelle précise.

1.2 Structure du jeu de données

Le jeu de données brut contient **16 092 lignes** et **14 colonnes**. Les variables principales sont décrites dans le Tableau 1.

1. <https://www.kaggle.com/datasets/melissamonfared/indicators-of-anxiety-or-depression>

TABLE 1 – Description des variables du jeu de données

Variable	Type	Description
Indicator	Catégorielle	Type de symptôme mesuré (3 valeurs : anxiété, dépression, ou les deux combinés)
Group	Catégorielle	Catégorie de segmentation démographique (9 valeurs : By Age, By Sex, By State, etc.)
State	Catégorielle	État américain (52 valeurs, incluant le District of Columbia)
Subgroup	Catégorielle	Sous-groupe spécifique au sein du Group (78 valeurs, ex. : « 18–29 years », « Female »)
Phase	Catégorielle	Phase de collecte de l'enquête (17 phases, de 1.0 à 4.1)
Time Period	Entier	Identifiant de période au sein d'une phase (69 périodes distinctes)
Time Period Label	Chaîne	Libellé lisible de la période (plage de dates)
Time Period Start/End Date	Date	Dates de début et fin de la période d'enquête
Value	Réel	Variable cible : pourcentage estimé d'adultes déclarant des symptômes (%)
Low CI / High CI	Réel	Bornes inférieure et supérieure de l'intervalle de confiance à 95%
Confidence Interval	Chaîne	Représentation textuelle de l'intervalle de confiance
Quartile Range	Chaîne	Classification en quartiles (disponible uniquement pour les données par État)

Les trois indicateurs sont parfaitement équilibrés, avec 5 364 lignes chacun. Le groupe « By State » domine le jeu de données avec 10 557 lignes (51 États + D.C.), reflétant la granularité géographique de l'enquête.

1.3 État de l'art et différence dans l'approche

Le jeu de données *Household Pulse Survey* a été analysé par de nombreux étudiants et chercheurs, notamment sur des plateformes comme Kaggle. En analysant ces travaux (*Ahirwar, 2023*; *Sukanto, 2024*; *Maniishaak, 2024*) nous avons remarqué des points communs, mais aussi des limites méthodologiques que ce projet s'efforce de dépasser.

1.3.1 Approches existantes et limites

La plupart des projets utilisent uniquement les informations déjà présentes dans le fichier (comme les dates ou le nom de l'État). Si ces modèles affichent des résultats très élevés ($R^2 > 0.80$), ils souffrent souvent de deux biais :

- **L'apprentissage par cœur des dates (Mémoire temporelle)** : En mélangeant toutes les données, le modèle "devine" le passé parce qu'il connaît déjà le futur.
- **L'identification des États (Leakage Spatial)** : Sans informations supplémentaires, le modèle finit par apprendre par cœur les scores de chaque État au lieu de comprendre les causes réelles de la dépression.

1.3.2 Positionnement du projet

Nous avons choisi une méthode plus complexe mais plus rigoureuse :

- **Ajout de données réelles** : Nous avons ajouté des informations sur l'économie (chômage, revenus, éducation, pauvreté, assurance) pour expliquer les variations de santé mentale.
- **Un test plus difficile** : Nous avons forcé le modèle à prédire les résultats d'États qu'il n'avait jamais vus auparavant. Nous avons aussi supprimé les variables qui lui permettaient de "tricher" (comme l'année ou le nom de l'État).

C'est pourquoi notre score de réussite (R^2 d'environ 0,31) est plus bas que celui d'autres projets. Cependant, ce score reste **pertinent** : il montre la véritable influence de l'économie sur le moral des Américains, sans triche ni mémorisation.

2 Exploration et nettoyage des données

2.1 Analyse des valeurs manquantes

Nous avons d'abord examiné la complétude du jeu de données. Les résultats sont résumés dans le Tableau 2.

TABLE 2 – Valeurs manquantes dans le jeu de données brut

Colonne	Nombre de manquants	% manquants
Quartile Range	5 534	34.39%
Value	706	4.39%
Low CI	706	4.39%
High CI	706	4.39%
Confidence Interval	706	4.39%
Total	8 358	—

Deux schémas distincts se dégagent :

- **Quartile Range** (5 534 manquants) : cette colonne n'est renseignée que pour les données au niveau des États (Group = « By State »). Son absence pour les autres groupes est structurellement attendue et ne traduit pas un problème de qualité des données.
- **Value et intervalles de confiance** (706 manquants) : notre investigation a révélé que 702 de ces 706 lignes correspondent à **Phase** = -1, un indicateur signifiant qu'aucune donnée n'a été collectée pour ces périodes. Les 4 lignes restantes appartiennent aux Phases 4.0 et 4.1 et représentent vraisemblablement des estimations supprimées en raison d'une taille d'échantillon insuffisante.

2.2 Étapes de nettoyage

Sur la base de cette analyse, nous avons appliqué les opérations de nettoyage suivantes :

1. **Suppression des lignes avec Phase = -1** : ces 702 lignes ne contiennent aucune donnée d'enquête et sont donc non informatives.
2. **Suppression des lignes restantes avec Value manquant** : 4 lignes supplémentaires ont été retirées.
3. **Conversion des dates** : les colonnes de dates de début et fin de période ont été converties au format `datetime`, et nous avons extrait les variables **Year** (année) et **Month** (mois) pour faciliter l'analyse temporelle.
4. **Suppression de colonnes redondantes** : la colonne **Confidence Interval** (redondante avec **Low CI** et **High CI**) et la colonne **Quartile Range** (pertinente uniquement pour l'analyse par État) ont été retirées.

Après nettoyage, le jeu de données contient **15 386 lignes** et **14 colonnes** avec **aucune valeur manquante**.

2.3 Analyse univariée de la variable cible

La variable cible **Value** représente le pourcentage estimé d'adultes déclarant des symptômes. Ses principales statistiques descriptives sont présentées dans le Tableau 3.

La distribution est asymétrique à droite (*skewness* = 0.818), avec une queue étendue vers les valeurs élevées. Le maximum de 85.2% correspond à des sous-groupes particulièrement vulnérables. L'histogramme et le boxplot de **Value** sont présentés en Figure 1.

TABLE 3 – Statistiques descriptives de la variable Value

Statistique	Valeur
Moyenne	28.58%
Écart-type	8.78%
Minimum	4.70%
1 ^{er} quartile (Q1)	22.70%
Médiane	28.10%
3 ^e quartile (Q3)	33.60%
Maximum	85.20%
Asymétrie (<i>skewness</i>)	0.818




FIGURE 1 – Histogramme et Boxplot de Value

2.4 Analyse par type d'indicateur

La décomposition de la distribution par type d'indicateur révèle des différences importantes (Tableau 4).

Les symptômes de dépression sont systématiquement rapportés à des taux inférieurs à ceux de l'anxiété. L'indicateur combiné (« Anxiété ou Dépression ») produit naturellement les valeurs les plus élevées, puisqu'il capture les individus souffrant de l'une ou l'autre condition. Ces résultats sont cohérents avec les estimations pré-pandémiques du NHIS 2019 rapportées par le CDC (8.1% pour l'anxiété seule, 6.5% pour la dépression seule, 10.8% combinés), bien que les valeurs de l'ère pandémique soient considérablement plus élevées.

TABLE 4 – Statistiques descriptives de Value par type d'indicateur.

Indicateur	Effectif	Moyenne	Écart-type	Médiane	Max
Symptômes d'anxiété	5 128	28.95	7.74	28.7	78.1
Symptômes de dépression	5 129	23.25	6.89	22.8	70.4
Anxiété ou dépression	5 129	33.55	8.40	33.3	85.2

2.5 Analyse par groupe démographique

Nous avons examiné la distribution de Value à travers les 9 groupes de segmentation démographique via des boxplots (Figure 2). Les groupes *By Sexual orientation*, *By Disability status* et *By Gender identity* présentent les médianes les plus élevées et les dispersions les plus importantes, traduisant de fortes disparités internes. À l'inverse, *By Sex* et *National Estimate* affichent des distributions resserrées.

Le groupe *By Gender identity* se distingue par une étendue particulièrement large, avec des valeurs s'étendant de 20% à 60%, ce qui traduit une forte hétérogénéité au sein de ce groupe. Cela est cohérent avec la présence de valeurs extrêmes visibles sur le boxplot.




FIGURE 2 – Boxplots de la distribution de Value par groupe démographique

2.6 Analyse par sous-groupes détaillés

Nous avons ensuite détaillé la distribution des taux de symptômes au sein de quatre catégories démographiques (Figures 3).




FIGURE 3 – Boxplots de la distribution de Value par groupe démographique

On observe que le mal-être diminue nettement avec l'âge : les jeunes de 18 à 29 ans sont les plus touchés (médiane de 42 %), alors que les 70-79 ans le sont beaucoup moins (15 %). Les femmes rapportent des taux plus élevés que les hommes (environ 32 % contre 25 %).

Le niveau d'études joue aussi un rôle important : les personnes sans diplôme sont plus vulnérables (médiane de 35 %) que celles ayant un diplôme universitaire (22 %). Enfin, les populations hispaniques et les autres minorités affichent les taux les plus hauts, tandis que les personnes d'origine asiatique présentent les niveaux les plus bas (environ 22 %).

2.7 Tendances temporelles

La Figure 4 présente l'évolution des estimations nationales de 2020 à 2024. Les trois indicateurs suivent une dynamique similaire : une montée rapide au second semestre 2020, un **pic fin 2020 – début 2021** (l'indicateur combiné atteignant environ 43%), puis une **baisse marquée jusqu'à mi-2021**. La période 2022–2023 montre une relative stabilisation avec de légères remontées ponctuelles. En fin de période (début 2024), on observe une **chute notable** de tous les indicateurs, la dépression descendant sous les 15%. Les trois courbes restent ordonnées de façon constante : le combiné au-dessus, suivi de l'anxiété, puis de la dépression.




FIGURE 4 – Estimation de la tendance nationale des symptômes entre 2020 et 2024

2.8 Analyse des intervalles de confiance

L'analyse de la précision des données montre une marge d'erreur moyenne (intervalle de confiance) de 7,3 points. La majorité des observations sont assez précises, avec des erreurs concentrées entre 7 et 8 points. Cependant, nous observons que pour les taux de dépression les plus élevés (au-dessus de 50 %), la marge d'erreur augmente fortement (plus de 15 points). Cela indique que les estimations sont moins fiables pour les populations les plus vulnérables, probablement à cause d'un échantillon plus restreint dans ces catégories.




FIGURE 5 – Distribution de la largeur de l'intervalle de confiance

3 Enrichissement du jeu de données par des variables socio-économiques

3.1 Motivation et construction du panel spatio-temporel

Conformément aux recommandations du professeur et pour affiner nos modèles prédictifs, nous avons enrichi le jeu de données en exploitant à la fois la dimension géographique (**State**) et temporelle (**Year**). Pour chaque État et chaque année de la période 2020-2024, nous avons ajouté cinq variables socio-économiques issues de l'American Community Survey (ACS) du U.S. Census Bureau ² :

2. <https://data.census.gov>

TABLE 5 – Variables d’enrichissement et tables sources (ACS 2020-2024)

Variable	Table ACS	Description
median_household_income	S1901	Revenu médian des ménages (\$)
poverty_rate	S1701	Taux de pauvreté (%)
pct_bachelors_or_higher	S1501	% de la pop. 25+ avec un bachelor
pct_uninsured	S2701	% sans assurance santé
unemployment_rate	DP03	Taux de chômage (%)

Contrairement à une approche statique basée sur une seule année de référence, la construction de ce panel de données nous permet d’étudier la dynamique temporelle. Nous pouvons ainsi observer comment les chocs macro-économiques brusques (comme l’explosion du chômage à près de 10 % en 2020 suivie de la reprise) influencent directement les variations de la santé mentale au fil du temps. Après fusion, le dataset enrichi contient 10 557 observations au niveau des États, couvrant l’ensemble de la période pandémique et post-pandémique.

3.2 Analyse des corrélations dynamiques

La Figure 6 présente la matrice de corrélation calculée sur l’ensemble du panel (États et années).

Le **revenu médian** apparaît comme la variable la plus fortement (et négativement) corrélée au taux de symptômes ($r = -0.53$), suggérant une association entre des niveaux de revenu plus élevés et une moindre prévalence de détresse psychologique.

À l’inverse, les marqueurs de précarité et d’instabilité sont associés à des niveaux plus élevés de symptômes : le **taux de pauvreté** ($r = 0.37$) et le **taux de chômage** ($r = 0.36$) montrent une corrélation positive quasi-identique avec la hausse des troubles. Le niveau d’éducation est également négativement corrélié ($r = -0.35$ pour les diplômés d’un bachelor ou plus), tandis que la proportion de personnes non assurées présente une corrélation positive plus modérée ($r = 0.23$).

On note par ailleurs une très forte colinéarité structurelle entre les variables économiques elles-mêmes, en particulier entre le revenu médian et le niveau d’éducation ($r = 0.81$), ainsi qu’une relation fortement inverse entre le revenu et le taux de pauvreté ($r = -0.67$).




FIGURE 6 – Matrice de corrélation spatio-temporelle : Économie vs Santé Mentale (Panel 2020-2024)

Les scatter plots (Figure 7), regroupent toutes les périodes pour chaque État. Ils confirment une tendance claire : plus les revenus sont élevés, plus les troubles psychologiques diminuent. Cela illustre bien le rôle de "bouclier" que joue la richesse face au mal-être.

Relations Économie vs Symptômes (Chaque point = 1 État sur 1 Année)




FIGURE 7 – Relations entre variables socio-économiques et taux de symptômes (Chaque point = 1 État pour 1 Année)

3.3 Analyse par indicateur

La corrélation entre la précarité et les symptômes varie selon le type d'indicateur étudié (Tableau 6). En effet, la **dépression isolée** apparaît comme le trouble le plus sensible aux facteurs macro-économiques, affichant la plus forte corrélation avec la pauvreté ($r = +0.42$) et la plus forte protection par le revenu ($r = -0.57$).

TABLE 6 – Corrélation avec le taux de symptômes par indicateur (Panel 2020-2024)

Indicateur	r(pauvreté)	r(revenu)
Symptômes de dépression	+0.42	-0.57
Anxiété ou dépression	+0.35	-0.51
Symptômes d'anxiété	+0.33	-0.50

3.4 Classement Global des États (Moyenne 2020-2024)

En lissant les données temporelles afin d'obtenir une vision globale de la période, la Figure 8 présente les 10 États les plus et les moins touchés en moyenne.

Les États les plus touchés (Louisiana, Mississippi, Oklahoma) correspondent à des territoires historiquement associés à des indicateurs socio-économiques moins favorables, ce qui est cohérent avec les corrélations observées précédemment.

À l'inverse, les États les moins touchés (South Dakota, Minnesota, Wisconsin) présentent en moyenne des conditions socio-économiques plus favorables.

Ces résultats suggèrent une association entre contexte socio-économique et prévalence des symptômes, sans toutefois permettre d'établir une relation causale directe.




FIGURE 8 – Top 10 (rouge) et Bottom 10 (vert) des États par taux de symptômes (Moyenne globale 2020-2024)

4 Tâche 1 : Régression Supervisée - Prédiction du taux de symptômes

L'objectif de cette première tâche est d'évaluer dans quelle mesure les indicateurs socio-économiques d'un État (revenu, chômage, éducation, etc.) permettent de prédire son taux de détresse psychologique (*Value*) sur la période 2020-2024.

Plutôt que de nous contenter d'un modèle unique, nous avons adopté une démarche itérative d'investigation. L'enjeu était d'identifier et d'éliminer progressivement les biais de prédiction (fuites de données) inhérents à la structure spatio-temporelle de notre jeu de données.

Note sur les données socio-économiques : Dans notre première version, nous n'avions récupéré les données socio-économiques que pour l'année 2021 (depuis l'ACS du Census Bureau). Or, notre dataset couvre la période 2020-2024. Utiliser des données fixes pour toute la période posait un problème : le taux de chômage, par exemple, a beaucoup varié entre 2020 (pic COVID) et 2024 (retour à la normale). Nous avons donc élargi notre collecte pour obtenir les données ACS de 2020 à 2024, ce qui permet à chaque ligne du dataset d'être associée aux indicateurs socio-économiques de la bonne année.

4.1 Première approche : Le modèle naïf et le biais géographique

Dans notre première itération, nous avons entraîné plusieurs modèles de régression (dont un Gradient Boosting Regressor) sur l'intégralité des données. Le jeu de données a été séparé de manière aléatoire classique (`train_test_split` à 80/20).

- **Résultat observé :** Le modèle Gradient Boosting a atteint un coefficient de détermination exceptionnel de $R^2 = 0.87$.
- **Analyse critique :** En sciences sociales et comportementales, un tel niveau de précision pour prédire un phénomène aussi complexe que la santé mentale semble irréaliste. L'analyse de notre méthodologie a révélé une **fuite de données spatiale (Spatial Data Leakage)**.

En effet, comme nous avons plusieurs relevés pour chaque État, un mélange aléatoire place des données du même État à la fois dans l'entraînement et le test. Les chiffres économiques (comme le taux de pauvreté) servent alors d'incateur unique : le modèle reconnaît l'État et redonne simplement sa moyenne habituelle au lieu de comprendre le lien entre économie et santé.

4.2 Deuxième tentative : Le colmatage spatial et la découverte du modèle "paresseux"

Afin de forcer le modèle à généraliser, nous avons remplacé le découpage aléatoire par un `GroupShuffleSplit` (basé sur la variable *State*). Ainsi, l'algorithme a été entraîné sur 40 États et testé sur 11 États qu'il n'avait *jamais* rencontrés.

- **Résultat observé** : Contre toute attente, à nouveau le modèle Gradient Boosting a atteint un score très élevé, avec un $R^2 = 0.82$.
- **L'investigation (Feature Importances)** : Comment le modèle pouvait-il prédire avec une telle précision la situation d'États inconnus ? Pour comprendre ce phénomène, nous avons extrait l'importance des variables (*Feature Importances*) de notre meilleur estimateur. Voici donc les résultats :
 - **Indicator_enc** (Type de trouble) : **49.3 %** de la décision.
 - **Year** (Année de la mesure) : **33.0 %** de la décision.
 - Variables socio-économiques combinées : moins de **18 %**.
- **Conclusion de l'étape** : Le modèle a exploité deux biais qui représentent plus de 82 % de son pouvoir prédictif. Premièrement, il s'est appuyé sur *Indicator_enc* car la catégorie combinée ("Anxiété OU Dépression") affiche mathématiquement des scores toujours plus élevés que les troubles isolés. Deuxièmement, il a utilisé la variable *Year* pour capter l'évolution globale de la pandémie (par exemple, avec le pic de 2020), en négligeant ainsi les variations économiques (chômage, revenus...) propres à chaque État.

4.3 Troisième tentative : L'isolement strict de l'impact économique

Après ces constats, on a décidé de retirer les deux variables qui faussaient les résultats. On ne garde que les lignes de dépression (ce qui élimine *Indicator_enc*), et on retire *Year* des features. Le modèle n'a plus que 5 variables purement économiques : revenu médian, taux de pauvreté, pourcentage de diplômés, pourcentage de non-assurés et taux de chômage.

4.3.1 Modèles évalués

On a testé 7 modèles, d'abord avec des paramètres par défaut, puis après optimisation par `GridSearchCV` avec un `GroupKFold` à 5 folds. Le Tableau 7 présente tous les résultats.

TABLE 7 – Performances de tous les modèles de régression (après suppression des biais)

Modèle	Test MAE	Test RMSE	Test R^2
Régression linéaire	3.438	4.288	0.285
Ridge ($\alpha = 1.0$)	3.438	4.288	0.285
SGD Regressor	3.440	4.290	0.285
KNN ($k = 10$)	3.837	4.787	0.109
SVR (RBF, $C = 10$)	3.364	4.289	0.285
Random Forest	3.533	4.410	0.244
Gradient Boosting	3.652	4.589	0.182
Ridge (tuné, $\alpha = 100$)	3.425	4.289	0.285
SGD (tuné, L1, $\alpha = 0.1$)	3.420	4.286	0.286
SVR (tuné, $C = 1$)	3.317	4.262	0.294
Random Forest (tuné)	3.506	4.405	0.246
Gradient Boosting (tuné)	3.461	4.371	0.257
KNN (tuné, $k = 30$)	3.338	4.208	0.312

4.3.2 Analyse des résultats

Un constat important : une fois les biais retirés, tous les modèles donnent des scores proches (Figure 9). Les R^2 vont de 0.11 à 0.31, et les MAE de 3.3 à 3.5 points. Aucun modèle complexe ne fait vraiment mieux qu'un modèle linéaire simple. Cela suggère que la relation entre variables économiques et taux de dépression

est principalement linéaire, sans interactions complexes supplémentaires qu'un arbre de décision pourrait exploiter.

Le KNN tuné ($k = 30$) obtient les meilleures performances, avec un coefficient de détermination R^2 de 0.312, indiquant que le modèle capture environ **31%** de la variabilité du taux de dépression. Le fait que le k optimal soit élevé (30 voisins) indique que le modèle repose sur un fort lissage, en agrégeant un grand nombre d'observations voisines. Cela suggère que les relations entre variables sont relativement bruitées ou peu discriminantes, et que le modèle privilégie une estimation stable au détriment de la finesse locale.

Les méthodes ensemblistes (Random Forest, Gradient Boosting), qui dominaient dans nos configurations précédentes, sont ici en retrait ($R^2 \approx 0.25$). Avec seulement une quarantaine d'États distincts en entraînement, ces modèles n'ont pas assez de diversité pour exploiter leur complexité et finissent par sur-apprendre.

4.3.3 Vérification de l'overfitting

Le Tableau 8 compare les scores sur le train et le test pour chaque modèle.

TABLE 8 – Vérification de l'overfitting — Régression

Modèle	Train R^2	Test R^2	Écart
Régression linéaire	0.300	0.285	0.015
SVR (tuné)	0.362	0.294	0.068
KNN (tuné, $k = 30$)	0.444	0.312	0.133
Random Forest (tuné)	0.450	0.246	0.204
Gradient Boosting (tuné)	0.482	0.257	0.225
Ridge (tuné)	0.299	0.285	0.014

Les modèles simples (régression linéaire, SVR, Ridge) ne montrent pas d'overfitting significatif. Le KNN présente un écart plus modéré, suggérant un léger sur-apprentissage. En revanche, le Random Forest et le Gradient Boosting ont des écarts train/test supérieurs à 0.20, ce qui confirme un sur-apprentissage marqué. Cela s'explique par le nombre limité d'États distincts en entraînement, qui ne permet pas à ces modèles d'exploiter pleinement leur complexité. C'est pour cela que ces modèles, habituellement les plus performants, sont ici moins bons que le KNN ou la régression linéaire : ils sont trop complexes pour ce type de données.




FIGURE 9 – Comparaison des 7 modèles : MAE (à gauche) et R^2 (à droite)

Le scatter plot réel vs prédit (Figure 10) montre bien les limites. Les prédictions tournent autour de 20–27%, la tendance est correcte (les États pauvres ont des taux plus élevés), mais il y a beaucoup de dispersion. Le modèle capte la direction générale sans pouvoir prédire les valeurs extrêmes.




FIGURE 10 – Valeurs réelles vs prédites — KNN tuné ($k = 30$)

4.3.4 Importance des variables

Le KNN étant un modèle basé sur les distances, il ne fournit pas directement d’importance des variables. On utilise donc les coefficients de la régression Ridge (qui a un R^2 très proche, 0.285 vs 0.312) pour comprendre quelles variables pèsent le plus (Tableau 9).

TABLE 9 – Importance des variables (coefficients Ridge normalisés)

Variable	Poids (%)
Revenu médian	43.3
Taux de chômage	41.1
% non-assurés	9.4
Taux de pauvreté	3.6
% diplômés bachelor+	2.6

Le **revenu médian** (43.3%) et le **taux de chômage** (41.1%) dominent largement, suivis du pourcentage de non-assurés (9.4%). Le taux de pauvreté et le niveau d’éducation pèsent peu (3.6% et 2.6%), probablement parce que leur information est déjà captée par le revenu médian avec lequel ils sont fortement corrélés ($r = -0.71$ et $r = 0.82$ respectivement).

Ce résultat est cohérent d’un point de vue économique : le revenu et l’emploi sont les deux facteurs les plus directement liés au quotidien des ménages et donc à leur niveau de stress.

4.3.5 Conclusion de la tâche

Un R^2 de 0.31 veut dire que 70% de la variance reste inexpliquée. C'est normal : la santé mentale dépend de beaucoup de facteurs qu'on n'a pas dans notre modèle — l'isolement social, les antécédents médicaux, l'accès aux soins psychologiques, l'exposition directe au COVID, ou encore la culture propre à chaque État. Notre résultat montre que l'économie compte, mais qu'elle est loin d'être le seul facteur.

4.4 Tentative d'amélioration : Le Bagging en Régression

Pour essayer de dépasser les scores obtenus, nous avons testé la méthode du **Bagging** (Bootstrap Aggregating). Cette technique consiste à entraîner plusieurs fois le même algorithme sur des échantillons aléatoires des données pour stabiliser les prédictions.

- **Bagging KNN (k=10)** : Ce test est pertinent. Alors que notre modèle KNN simple avec $k = 10$ stagnait à un R^2 de 0,109, le passage au Bagging a permis de doubler sa performance pour atteindre **0,218**. Cela prouve que le Bagging est extrêmement efficace pour corriger les erreurs de modèles "instables".
- **Bagging KNN (k=30)** : Puisque notre meilleur modèle de base était le KNN avec $k = 30$ ($R^2 = 0,312$), nous lui avons appliqué le Bagging. Le gain est marginal, car le modèle était déjà très lissé et stable, mais il nous permet d'atteindre un R^2 de **0,317**.
- **Bagging Tree** : Nous avons aussi testé un Bagging d'arbres de décision. Le résultat obtenu ($R^2 = 0,234$) est proche de celui du Random Forest (0,246), mais reste en dessous.

Conclusion de l'étape : Bien que le Bagging améliore nettement certains modèles, il ne permet pas de battre notre meilleur score de **0,312** obtenu avec le KNN ($k = 30$). Cela confirme que pour ces données, un lissage important (grand nombre de voisins) est plus efficace qu'une multiplication de modèles complexes.

5 Tâche 2 : Classification supervisée — Prédiction du risque critique

5.1 Première approche et ses limites

Notre première idée a été de prédire le type de trouble (anxiété, dépression, ou les deux combinés) à partir du taux de symptômes et des variables socio-économiques. Mais cette approche s'est révélée quasi-circulaire. Pour un même État à une même période, les features socio-économiques sont identiques entre les 3 indicateurs : seule **Value** change. Or, la dépression a toujours des valeurs plus basses ($\approx 23\%$) que le combiné ($\approx 33\%$). Le modèle apprenait donc juste un seuil sur **Value**, ce qui rend la classification triviale. Et retirer **Value** des features rendait la tâche impossible, puisque les 3 classes auraient alors exactement les mêmes features (accuracy $\approx 33\%$, le hasard).

De plus, d'un point de vue clinique, la précarité financière accroît la vulnérabilité psychologique globale mais ne détermine pas si quelqu'un va développer de l'anxiété *plutôt* que de la dépression. Essayer de distinguer les deux à partir de l'économie n'a donc pas de sens.

5.2 Reformulation : prédire l'état critique

Ce constat nous a poussés à transformer le problème en une classification binaire plus pertinente. La question devient : « *Le profil socio-économique d'un État permet-il d'anticiper si sa population franchira un seuil d'alerte en matière de dépression ?* »

En cohérence avec la Tâche 1, on garde uniquement les données de dépression et on utilise les 5 variables socio-économiques comme features (sans **Value**, sans **Year**, sans **Indicator_enc**). La médiane de **Value** se situant autour de 22.6%, on fixe le seuil d'alerte à **22%** pour équilibrer les classes :

- **Classe 1 (zone critique)** : taux de dépression $\geq 22\%$ (1 943 observations)
- **Classe 0 (zone normale)** : taux de dépression $< 22\%$ (1 576 observations)

Comme pour la régression, la validation utilise un **GroupShuffleSplit** et un **GroupKFold** basés sur l'État pour garantir l'absence de fuite spatiale.

5.3 Résultats

Six classifieurs ont été entraînés puis optimisés via `GridSearchCV` (Tableau 10).

TABLE 10 – Comparaison des modèles — Classification binaire (seuil 22%)

Modèle	CV Accuracy	Test Accuracy
Régression logistique	0.688	0.738
KNN ($k = 10$)	0.639	0.731
Naive Bayes	0.663	0.721
SVM (RBF, $C = 10$)	0.606	0.758
Random Forest	0.677	0.776
Gradient Boosting	0.625	0.660
Logistique (tuné, $C = 1$)	0.688	0.738
KNN (tuné, $k = 20$)	0.655	0.773
SVM (tuné, $C = 1$)	0.658	0.739
Random Forest (tuné)	0.680	0.760
Gradient Boosting (tuné)	0.671	0.711

Les modèles atteignent entre 66% et 78% d'accuracy. Le Random Forest non tuné est le meilleur (77.6%). Le tuning n'améliore pas ici, ce qui s'explique par le petit nombre d'États (51) et de features (5). Ce résultat reste satisfaisant pour les sciences sociales : dans environ 3 cas sur 4, l'économie seule permet de deviner si un État franchit le seuil critique, sans connaître le contexte de la pandémie.

5.4 Analyse de la matrice de confusion et courbe ROC

L'évaluation du Random Forest sur les 759 observations du test (États jamais vus) donne une matrice de confusion (Figure 11) :

- **Vrais Positifs (432)** : Le modèle a correctement identifié 432 situations où l'État se trouvait en "Zone Critique" (dépression $\geq 22\%$). Avec un *Recall* (sensibilité) de 87,6 %, le modèle démontre une excellente capacité à détecter la grande majorité des États en souffrance.
- **Vrais Négatifs (157)** : Le modèle a correctement identifié 157 cas où l'État se trouvait dans une situation psychologique stable (dépression $< 22\%$).
- **Faux Négatifs (61)** : Seules 61 crises n'ont pas été anticipées par le modèle. Bien qu'il s'agisse de l'erreur la plus dangereuse du point de vue de la santé publique (rater une population en détresse), ce chiffre reste heureusement très bas.
- **Faux Positifs (109)** : Le modèle génère un nombre significatif de "fausses alertes" (109 États présumés en crise alors qu'ils étaient sous le seuil). Ce cas est moins grave : il vaut mieux déclencher une alerte préventive inutilement (Faux Positif) plutôt que d'ignorer un État qui sombre dans une crise psychologique sévère (Faux Négatif).




FIGURE 11 – Matrice de confusion — Random Forest

La courbe ROC (Figure 12) confirme la capacité de discrimination du modèle avec une AUC de 0.77, bien au-dessus d'un classifieur aléatoire (0.50).




FIGURE 12 – Courbe ROC — Random Forest (AUC = 0.77)

TABLE 11 – Precision, recall et F1-score par classe (Random Forest)

Classe	Precision	Recall	F1-Score
< 22% (normale)	0.720	0.590	0.649
≥ 22% (critique)	0.799	0.876	0.836

Du point de vue des politiques publiques, ce profil de performance (recall élevé, précision modérée) est particulièrement pertinent. En matière de prévention de santé mentale, il vaut mieux déclencher une fausse alerte pour un État (faux positif) plutôt que de rater un État en situation critique (faux négatif). L'économie peut ainsi constituer un bon système d'alerte précoce.

5.5 Vérification de l'overfitting

Contrairement à la régression, aucun modèle ne présente de sur-apprentissage significatif (Tableau 12). Les écarts train/test sont tous faibles (inférieurs à 0.05), et certains modèles affichent même une accuracy légèrement supérieure sur le test. Cela peut s'expliquer par le fait que les États du jeu de test présentent des profils économiques plus marqués, les rendant plus faciles à classer.

TABLE 12 – Vérification de l'overfitting — Classification

Modèle	Train Acc	Test Acc	Écart
Logistique (tuné)	0.678	0.738	−0.060
KNN (tuné)	0.757	0.773	−0.017
SVM (tuné)	0.717	0.739	−0.022
Random Forest (tuné)	0.758	0.760	−0.002
Gradient Boosting (tuné)	0.762	0.711	0.050

5.6 Analyse complémentaire : Le Bagging peut-il battre le Random Forest ?

Pour la classification (seuil critique de 22 %), notre meilleur modèle initial était le **Random Forest avec une accuracy de 77,6 %**. Nous avons voulu vérifier si l'application d'un Bagging sur d'autres algorithmes permettait de dépasser ce score.

- **Bagging KNN (k=20)** : En appliquant le Bagging sur notre meilleur KNN (**77,3 %**) , nous obtenons une accuracy de **76,0 %**. C'est un score très solide, mais insuffisant pour prendre la première place.
- **Bagging Tree** : Un Bagging d'arbres de décision simples atteint **74,4 %** d'accuracy.

Conclusion finale : Le vainqueur de la classification reste le **Random Forest**.

6 Tâche 3 : Analyse non supervisée

6.1 Objectif et choix méthodologiques

L'objectif est de regrouper les 51 États américains selon leurs caractéristiques socio-économiques et leur taux moyen de symptômes, sans étiquette prédéfinie. On veut voir si des groupes naturels se forment et s'ils correspondent à des réalités géographiques connues.

Pour chaque État, on calcule un profil moyen (moyenne sur toutes les périodes 2020–2024) avec 6 variables : taux moyen de symptômes, revenu médian, taux de pauvreté, pourcentage de diplômés, pourcentage de non-assurés et taux de chômage. Les features sont standardisées car leurs échelles sont très différentes.

On applique d'abord une **PCA** pour visualiser les données en 2D, puis un **K-Means** pour regrouper les États, et enfin un **clustering hiérarchique** pour vérifier la robustesse des groupes.

6.2 Analyse en composantes principales (PCA)

La PCA révèle que les deux premières composantes capturent 79.5% de la variance totale (PC1 : 56.4%, PC2 : 23.1%), et que 3 composantes suffisent pour dépasser 91% (Figure 13).




FIGURE 13 – Variance expliquée par composante (à gauche) et variance cumulée (à droite)

L'analyse des contributions (Tableau 13) montre que PC1 oppose les États défavorisés (symptômes élevés, pauvreté, non-assurés, à droite) aux États favorisés (revenu et éducation élevés, à gauche). PC2 est principalement portée par le taux de chômage. La projection 2D des États (Figure 14) met en évidence une structure continue avec quelques outliers, notamment le District of Columbia (revenu et éducation très élevés mais chômage fort) et le Mississippi (pauvreté élevée, à l'extrême droite).

TABLE 13 – Contribution des features aux deux premières composantes

Feature	PC1	PC2
mean_value	0.478	0.269
median_household_income	-0.458	0.351
poverty_rate	0.466	0.222
pct_bachelors_or_higher	-0.435	0.381
pct_uninsured	0.348	-0.142
unemployment_rate	0.187	0.768




FIGURE 14 – Projection PCA des 51 États sur les deux premières composantes

6.3 K-Means

La méthode du coude (Figure 15) suggère un coude à $k = 3$. Le K-Means avec 3 clusters produit un score de silhouette de 0.309. Le Tableau 14 résume le profil moyen de chaque cluster et la Figure 16 montre leur projection sur la PCA.




FIGURE 15 – Méthode du coude pour le choix de k


TABLE 14 – Profil moyen des 3 clusters (K-Means)

Cluster	Symptômes	Revenu	Pauvreté	% Diplômés	% Non-ass.	Chômage
Vulnérables (20)	24.7%	\$61k	14.9%	29.5%	9.6%	5.3%
Intermédiaires (14)	20.5%	\$71k	10.6%	34.5%	7.1%	3.5%
Favorisés (17)	21.9%	\$83k	11.2%	40.2%	6.0%	5.5%

Les trois clusters correspondent à des profils interprétables :

- **Vulnérables** (20 États, en rouge) : regroupe des États du Sud et du Sud-Ouest (Louisiana, Mississippi, Alabama, Texas, etc.) caractérisés par les taux de symptômes les plus élevés (24.7%), les revenus les plus faibles et les taux de pauvreté et de non-assurés les plus importants.
- **Intermédiaires** (14 États, en vert) : des États du Midwest et du Nord (Iowa, Wisconsin, Montana, etc.) avec le taux de symptômes le plus bas (20.5%), des revenus moyens et surtout le chômage le plus faible (3.5%).
- **Favorisés** (17 États, en bleu) : des États du Nord-Est et de la côte Ouest (Massachusetts, California, D.C., etc.) avec les revenus les plus élevés et le taux de diplômés le plus fort (40.2%).

Un résultat intéressant : les États « Favorisés » n'ont pas le taux de symptômes le plus bas (21.9% contre 20.5% pour les Intermédiaires). Cela peut s'expliquer par leur chômage plus élevé (5.5% contre 3.5%) et par d'autres facteurs de stress liés au coût de la vie dans les grandes métropoles.

FIGURE 16 – K-Means ($k = 3$) projeté sur les deux premières composantes de la PCA

6.4 Clustering hiérarchique

Le dendrogramme (méthode de Ward, Figure 17) confirme la structure en 3 groupes. La première scission sépare les États favorisés (à gauche, en orange) du reste. Les États vulnérables et intermédiaires se séparent

ensuite à un niveau de distance plus bas.

Le score de silhouette du clustering hiérarchique (0.274) est légèrement inférieur à celui du K-Means (0.309), mais la comparaison côte à côte (Figure 18) montre que les deux méthodes produisent des regroupements similaires, avec quelques États qui changent de groupe aux frontières entre clusters. Cette cohérence entre deux algorithmes très différents confirme que les 3 profils identifiés ne sont pas un artefact mais reflètent une vraie structure dans les données.




FIGURE 17 – Dendrogramme — Clustering hiérarchique (méthode de Ward)




FIGURE 18 – Comparaison K-Means (à gauche) et hiérarchique (à droite), projetés sur la PCA

7 Conclusion

7.1 Ce qu'on a trouvé

Ce projet nous a permis d'étudier le lien entre les conditions économiques des États américains et la santé mentale de leur population pendant et après la pandémie de COVID-19.

En régression, après avoir corrigé plusieurs biais (fuite spatiale, variables "triches"), on a montré que les variables socio-économiques expliquent environ 31% de la variance du taux de dépression ($R^2 = 0.312$). Le revenu médian (43%) et le taux de chômage (41%) sont les deux facteurs qui pèsent le plus. C'est un résultat modeste en termes de prédiction, mais il confirme que l'économie joue un rôle réel dans la santé mentale.

En classification, le modèle arrive à prédire dans 77.6% des cas si un État va dépasser le seuil critique de 22% de dépression, en se basant uniquement sur son profil économique. Le recall de 87.6% sur les États en crise en fait un bon outil d'alerte précoce : il vaut mieux déclencher une fausse alerte que rater un État en difficulté.

En non supervisé, le clustering a fait émerger 3 profils d'États (vulnérables, intermédiaires, favorisés) qui correspondent bien à la géographie américaine connue. Un résultat inattendu : les États les plus riches n'ont pas le taux de symptômes le plus bas, ce qui suggère que d'autres facteurs de stress (coût de la vie, chômage urbain) entrent en jeu.

7.2 Les difficultés rencontrées

La principale difficulté a été d'identifier et de corriger les biais dans nos modèles. Notre première approche donnait un R^2 de 0.87, un score trop beau pour être vrai. L'analyse a révélé deux problèmes : une fuite de données spatiale (les mêmes États dans le train et le test) et des variables "triches" (*Indicator_enc* et *Year*) qui masquaient le vrai signal économique. La même rigueur a été appliquée à la classification, où notre première formulation (prédire le type d'indicateur) s'est révélée quasi-circulaire.

Cette démarche itérative (obtenir un résultat suspect, l'analyser, identifier le problème, corriger) a été la partie la plus formatrice du projet.

7.3 Les limites

Plusieurs limites doivent être mentionnées. Le nombre d'États est petit (51), ce qui limite la capacité des modèles complexes (Random Forest, Gradient Boosting) à généraliser. Les 70% de variance non expliquée en régression montrent que l'économie seule ne suffit pas : l'isolement social, les antécédents médicaux, l'accès aux soins, l'exposition au COVID ou la culture propre à chaque État sont autant de facteurs absents de notre modèle. Enfin, nos données sont agrégées par État et non individuelles, ce qui expose au risque d'erreur écologique : une corrélation observée au niveau des États ne s'applique pas forcément au niveau des individus.

Note sur la reproductibilité (Random Forest) : Lors de l'exécution du script final (*main.py*), seul le modèle **Random Forest** a présenté une légère variation de performance par rapport au Jupyter Notebook (ex : de 77.6% à 74.6% en classification). Nous n'avons pas réussi à comprendre pourquoi une telle chose se produisait. Peut-être s'agit-il d'un problème lié aux différentes versions ?

7.4 Perspectives

Pour aller plus loin, on pourrait intégrer des variables dynamiques supplémentaires (taux de vaccination COVID, nombre de cas par État), utiliser les données individuelles du Household Pulse Survey (PUMS) plutôt que les agrégats, ou encore ajouter des variables sur l'accès aux soins psychologiques. Une analyse temporelle plus fine (séries temporelles par État) permettrait aussi de capter les dynamiques locales de la pandémie.

Références

- [1] M. Monfared, *Indicators of Anxiety or Depression*, Kaggle, 2024. <https://www.kaggle.com/datasets/melissamonfared/indicators-of-anxiety-or-depression>
- [2] U.S. Census Bureau, *Median Household Income by State, 2021 – Table S1901*, American Community Survey 1-Year Estimates. <https://data.census.gov/table?q=income+by+state+2021>
- [3] U.S. Census Bureau, *Poverty Status by State, 2021 – Table S1701*, American Community Survey 1-Year Estimates. <https://data.census.gov/table?q=poverty+rate+by+State+2021>
- [4] U.S. Census Bureau, *Educational Attainment by State, 2021 – Table S1501*, American Community Survey 1-Year Estimates. <https://data.census.gov/table?q=educational+by+state+2021>
- [5] U.S. Census Bureau, *Health Insurance Coverage by State, 2021 – Table S2701*, American Community Survey 1-Year Estimates. <https://data.census.gov/table?q=health+insurance+by+State+2021>
- [6] U.S. Census Bureau, *Unemployment Rate by State, 2021 – Table DP03*, American Community Survey 1-Year Estimates. <https://data.census.gov/table?q=Unemployment+rate+by+State+2021>
- [7] National Center for Health Statistics, *Mental Health – Household Pulse Survey – COVID-19*, Centers for Disease Control and Prevention, 2024. <https://www.cdc.gov/nchs/covid19/pulse/mental-health.htm>
- [8] C. Cai, S. Woolhandler, D.U. Himmelstein et al., “Trends in Anxiety and Depression Symptoms During the COVID-19 Pandemic : Results from the US Census Bureau’s Household Pulse Survey,” *Journal of General Internal Medicine*, vol. 36, pp. 1841–1843, 2021. <https://doi.org/10.1007/s11606-021-06759-9>
- [9] R. Donnelly et al., “Anxiety and Depression Risk Among Healthcare Workers During the COVID-19 Pandemic : Findings from the US Census Household Pulse Survey,” *Journal of General Internal Medicine*, 2022. <https://doi.org/10.1007/s11606-022-07978-4>
- [10] T. Richter et al., “Predictive modeling of depression and anxiety using electronic health records and a novel machine learning approach with artificial intelligence,” *Scientific Reports*, vol. 11, 2021. <https://doi.org/10.1038/s41598-021-81368-4>